## Middleware - Cloud Computing - Übung

MapReduce: Übersicht & Ablauf

Wintersemester 2020/21

Michael Eischer, Laura Lawniczak, Tobias Distler

Friedrich-Alexander-Universität Erlangen-Nürnberg
Lehrstuhl Informatik 4 (Verteilte Systeme und Betriebssysteme)
www4.cs.fau.de





#### <u>Über</u>blick

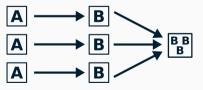
#### MapReduce

- Einführung und Grundlagen
- Ablauf eines MapReduce-Jobs
- Aufgaben des Frameworks

## MapReduce

Einführung und Grundlagen

- Programmiermodell zur Strukturierung von Programmen für parallele, verteilte Ausführung
- Map und Reduce ursprünglich Bausteine aus funktionalen Programmiersprachen (z. B. LISP)
  - Map: Abbildung eines Eingabeelements auf ein Ausgabeelement
  - Reduce: Zusammenfassung mehrerer gleichartiger Eingaben zu einer einzelnen Ausgabe
- Formulierung zu lösender Aufgaben in MapReduce
  - Aufteilen in (potentiell mehrere) Map- und Reduce-Schritte
  - Implementierung der Map- und Reduce-Methoden (Entwickler)
  - Parallelisierung und Verteilung (MapReduce-Framework)



- "MapReduce: Simplified data processing on large clusters" (OSDI'04)
- Ursprüngliche Implementierung von Google nicht öffentlich
- Zahlreiche Open-Source-Implementierungen (z. B. Apache Hadoop, Disco, MR4C)
  - → Ermöglicht Verarbeitung riesiger Datenmengen
  - → Vereinfachung der Anwendungsentwicklung

Literatur

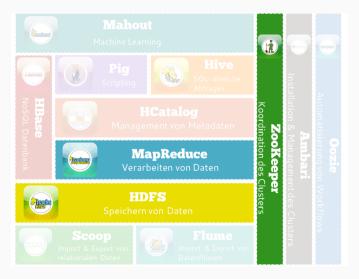


Jeffrey Dean and Sanjay Ghemawat

MapReduce: Simplified data processing on large clusters

Proceedings of the 6th Conference on Operating Systems Design and Implementation (OSDI '04), pages 137–150, 2004.

#### Hadoop-Framework (Komponenten)



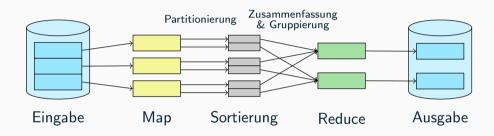
 $Quelle\ der\ Illustration:\ https://blog.codecentric.de/2013/08/einfuhrung-in-hadoop-die-wichtigsten-komponenten-von-hadoop-teil-3-von-5/2013/08/einfuhrung-in-hadoop-die-wichtigsten-komponenten-von-hadoop-teil-3-von-5/2013/08/einfuhrung-in-hadoop-die-wichtigsten-komponenten-von-hadoop-teil-3-von-5/2013/08/einfuhrung-in-hadoop-die-wichtigsten-komponenten-von-hadoop-teil-3-von-5/2013/08/einfuhrung-in-hadoop-die-wichtigsten-komponenten-von-hadoop-teil-3-von-5/2013/08/einfuhrung-in-hadoop-die-wichtigsten-komponenten-von-hadoop-teil-3-von-5/2013/08/einfuhrung-in-hadoop-tei$ 

### MapReduce

Ablauf eines MapReduce-Jobs

#### **Ablauf von MapReduce**

■ Übersicht: Ablauf eines MapReduce-Durchlaufs



■ Darstellung der Daten in Form von **Schlüssel-Wert-Paaren** 

4

- Abbildung in der Map-Phase
  - Parallele Verarbeitung verschiedener Teilbereiche der Eingabedaten
  - Eingabedaten in Form von Schlüssel-Wert-Paaren
  - Abbildung auf variable Anzahl von neuen Schlüssel-Wert-Paaren
- Beispiel: Zählen von Wörtern



■ Schnittstelle **Mapper** in Apache Hadoop

```
public class Mapper<KEYIN, VALUEIN, KEYOUT, VALUEOUT> {
  void map(KEYIN key, VALUEIN value, Context context) {
    context.write((KEYOUT) key, (VALUEOUT) value);
  }
}
```

- Festlegen von Datentypen mittels "Generics"
- Parameter:
  - key: Schlüssel, z. B. Zeilennummer
  - value: Wert, z. B. Inhalt der Zeile
  - context: Ausführungskontext, enthält write()-Methode zur Ausgabe von Schlüssel-Wert-Paaren

- Jeder Mapper referenziert einen Context
- Context verwaltet die Ein- und Ausgabe des Mappers
  - Stellt Reader zum Lesen von Schlüssel-Wert-Paare aus Eingabe des Mappers bereit
  - Sammelt und bereitet Schlüssel-Wert-Paare für die Ausgabe des Mappers vor (z.B. Partitionierung)
- Datenfluss im Mapper:
  - 1. Reader liest nächstes Schlüssel-Wert-Paar aus Eingabe
  - 2. Schlüssel-Wert-Paar wird an map-Funktion übergeben
  - 3. map-Funktion übergibt Context das Ergebnis
  - 4. Context schreibt Ergebnis in die Ausgabe

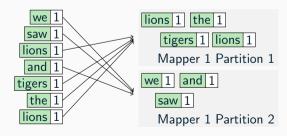
# Mapper map(k,v,c) write Context Ausgabe

#### **Context-Parameter in map**

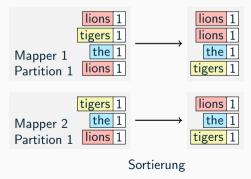
Der Parameter context in map zeigt auf das selbe Objekt, dass der Mapper intern verwendet. Diese Trennung erlaubt eine komfortablere Implementierung der map-Funktion.

- Zuordnung der Mapper-Ausgabe zu späterem Reducer
  - Gleiche Schlüssel müssen zu gleichem Reducer
  - Eingaben der einzelnen Reducer sind unabhängig ightarrow parallelisierbar
- Schnittstelle **Partitioner** in Apache Hadoop

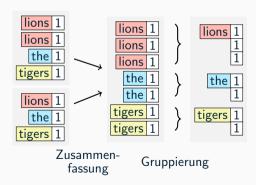
```
public class Partitioner<KEY, VALUE> {
  int getPartition(KEY key, VALUE value, int numPartitions) {
    return (key.hashCode() & Integer.MAX_VALUE) % numPartitions;
  }
}
```



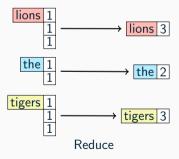
- Sortieren der Partitionen nach Schlüssel
  - Lokale Vorsortierung nach Verarbeitung der Daten durch Mapper
  - Jede Partition wird einzeln sortiert



- Zusammenfassen und Gruppierung der Daten nach Schlüssel
  - Eingaben für Reducer befinden sich in (mehreren) Mapper-Ausgaben
  - Zusammenfassung der vorsortierten Partitionen zu einer vollständig sortierten Gesamtliste
  - Gruppierung aller Werte unter identischem Schlüssel
  - Statt Schlüssel-Wert-Paar nun Schlüssel und Liste von Werten



- Zusammenführen von Daten in der Reduce-Phase
  - Eingabe in Form von Schlüssel und allen zugehörigen Werten aus Mapper
  - Parallele Verarbeitung verschiedener Teilbereiche von Schlüsseln
  - Abbildung auf variable Anzahl von neuen Schlüssel-Wert-Paaren



Schnittstelle Reducer in Apache Hadoop:

```
public class Reducer<KEYIN, VALUEIN, KEYOUT, VALUEOUT> {
  void reduce(KEYIN key, Iterable<VALUEIN> values, Context context) {
    for(VALUEIN value : values) {
        context.write((KEYOUT) key, (VALUEOUT) value);
    }
  }
}
```

- Parameter:
  - key: Schlüssel aus Sortierungsphase
  - values: Liste von Werten, welche zu dem Schlüssel gruppiert wurden
  - context: Ausführungskontext, enthält write()-Methode zur Ausgabe von Schlüssel-Wert-Paaren

# Aufgaben des Frameworks

MapReduce

#### Aufgaben des Frameworks

- Generelle **Steuerung** der MapReduce-Abläufe
  - Scheduling einzelner (Teil-)Aufgaben
  - Einhaltung der Reihenfolge bei Abhängigkeiten
  - Zwischenspeicherung der Daten
- Implementiert grundsätzliche Algorithmen (z. B. Sortierung)
- Bereitstellen von **Schnittstellen** zur Anpassung von
  - Dateneingabe (Deserialisierung)
  - Mapper
  - Partitionierung
  - Sortierung/Gruppierung
  - Reducer
  - Datenausgabe (Serialisierung)